

UTS MANAJEMEN DATA

Nama : Muhammad Naufal Syafry Putranto

NIM : 563544

Mata Kuliah : Manajemen Data Hasil Pengukuran

Eksplorasi Data Rapor Asesmen

1. Persiapan dan Pembersihan Data

Bagian ini adalah fondasi dari seluruh analisis. Di sini, data mentah diubah menjadi format yang siap diolah secara statistik.

```
5 # 1. Load packages
6 library(dplyr)
7 library(Amelia)
8 library(car)
9
10 # 2. Baca data
11 data_umum <- readRDS("Rapor asesmen Nasional SMA.RDS")
12
13 # 3. Konversi dan clean data
14 data_clean <- data_umum %>%
15   mutate(
16     # Konversi jumlah_siswa_penerima_PIP ke numeric
17     jumlah_siswa_penerima_PIP = case_when(
18       jumlah_siswa_penerima_PIP == "NULL" ~ NA_character_,
19       TRUE ~ jumlah_siswa_penerima_PIP
20     ),
21     jumlah_siswa_penerima_PIP = as.numeric(jumlah_siswa_penerima_PIP),
22
23     # Konversi jenis_sek ke factor
24     jenis_sek = as.factor(jenis_sek)
25   )
```

Prosedur ini mengintegrasikan sejumlah paket dalam ekosistem R. Paket *dplyr* diterapkan secara komprehensif untuk manipulasi data melalui berbagai fungsi seperti operator *pipe*, sementara paket *Amelia* dipergunakan secara spesifik untuk menangani data yang hilang melalui metodologi imputasi berganda. Lebih lanjut, paket *car* (*Companion to Applied Regression*) diimplementasikan untuk melakukan pengujian asumsi statistik yang rigor, terutama *Levene's test* guna mengevaluasi homogenitas varians antar kelompok. Tahap pembersihan data ini merupakan komponen krusial dalam kerangka kerja sains data, mengingat dataset mentah sering kali menunjukkan inkonsistensi, seperti penggunaan format teks "NULL" untuk merepresentasikan nilai kosong. Guna memitigasi hal tersebut, fungsi *case_when* digunakan untuk mentransformasikan representasi teks tersebut menjadi konstanta *NA* (*Not Available*) secara sistematis. Transformasi ini bertujuan agar sistem R dapat mengidentifikasi entri tersebut sebagai *missing value* yang valid, sehingga mencegah

terjadinya bias interpretasi pada saat analisis statistik atau kalkulasi matematis dilakukan. Langkah final dalam preparasi data adalah memastikan kesesuaian tipe data pada setiap variabel berdasarkan fungsinya. Variabel jumlah siswa dikonversi menjadi tipe *numerik* untuk memfasilitasi perhitungan agregat seperti rata-rata, median, dan standar deviasi. Di sisi lain, variabel jenis sekolah dikonversi menjadi tipe *faktor*. Kategorisasi ini sangat esensial untuk menetapkan struktur data kategorikal yang memungkinkan perbedaan formal antara kelompok SMA dan SMK dalam model analisis komparatif.

2. Penanganan Data Hilang (Imputasi Amelia)

```
51 if(missing_pip > 0) {  
52   cat("=== MELAKUKAN IMPUTASI AMELIA ===\n")  
53  
54   # Prepare data untuk Amelia (hanya variabel numerik)  
55   data_for_amelia <- data_analisis >  
56     select(jumlah_siswa_penerima_PIP, jumlah_peserta_didik, SES_sekolah) >  
57     as.data.frame()  
58  
59   # Jalankan Amelia dengan 5 imputasi  
60   set.seed(12345)  
61   amelia_out <- amelia(data_for_amelia,  
62                       m = 5, # 5 imputed datasets  
63                       idvars = NULL,  
64                       noms = NULL,  
65                       ords = NULL,  
66                       p2s = 0) # suppress progress bar  
67  
68   # Ambil dataset pertama hasil imputasi  
69   data_imputed <- amelia_out$imputations[[1]]  
70  
71   # Gabungkan kembali dengan jenis_sek  
72   data_final <- data_analisis >  
73     select(jenis_sek) >  
74     bind_cols(data_imputed)  
75  
76   cat("Imputasi selesai.\n\n")  
77 } else {  
78   cat("=== TIDAK ADA MISSING DATA - IMPUTASI TIDAK DIPERLUKAN ===\n\n")  
79   data_final <- data_analisis  
80 }
```

Metode ini mengimplementasikan algoritma *Expectation-Maximization with Bootstrapping* (EMB) guna menangani atrisi data secara sistematis. Berbeda dengan teknik imputasi tunggal, pendekatan ini menghasilkan sejumlah estimasi nilai guna mempresentasikan ketidakpastian statistik secara akurat. Algoritma EMB melakukan analisis mendalam terhadap korelasi dan pola distribusi pada variabel pendukung, seperti jumlah_peserta_didik dan SES_sekolah. Melalui identifikasi pola tersebut, sistem mampu memprediksi nilai estimasi yang optimal untuk variabel jumlah_siswa_penerima_PIP yang hilang, sehingga integritas struktur data tetap representatif terhadap kondisi populasi asli. Implementasi imputasi tersebut sangat fundamental dalam menjaga validitas dataset. Melalui pengisian data yang berlandaskan prinsip ilmiah, ukuran sampel dapat

dipertahankan secara maksimal, yang secara signifikan berkontribusi pada stabilitas kekuatan uji statistik (*Power Test*). Prosedur ini efektif dalam memitigasi risiko bias seleksi yang kerap timbul akibat penggunaan metode *listwise deletion*, sehingga inferensi yang dihasilkan dari analisis ini memiliki tingkat presisi yang lebih tinggi dan dapat dipertanggungjawabkan secara metodologis.

3. Uji Asumsi (Normalitas & Homogenitas)

Sebelum memilih uji statistik (Uji T atau Mann-Whitney), diperlukan syntax untuk memeriksa apakah data memenuhi syarat "Normal" dan "Homogen".

```
97 # 6. Uji normalitas per kelompok
98 cat("=== Uji NORMALITAS (SHAPIRO-WILK) ===\n")
99 sma_data <- data_final > filter(jenis_sek == "SMA") > pull(jumlah_siswa_penerima_PIP)
100 smk_data <- data_final > filter(jenis_sek == "SMK") > pull(jumlah_siswa_penerima_PIP)
101
102 if(length(sma_data) > 5000) {
103   set.seed(12345)
104   sma_sample <- sample(sma_data, 5000)
105 } else {
106   sma_sample <- sma_data
107 }
108
109 if(length(smk_data) > 5000) {
110   set.seed(12345)
111   smk_sample <- sample(smk_data, 5000)
112 } else {
113   smk_sample <- smk_data
114 }
115
116 shapiro_sma <- shapiro.test(sma_sample)
117 shapiro_smk <- shapiro.test(smk_sample)
118
119 cat("SMA: W =", round(shapiro_sma$statistic, 4), ", p =",
120     format.pval(shapiro_sma$p.value, digits = 3), "\n")
121 cat("SMK: W =", round(shapiro_smk$statistic, 4), ", p =",
122     format.pval(shapiro_smk$p.value, digits = 3), "\n\n")
123
```

Uji Shapiro-Wilk memiliki batasan teknis maksimal 5.000 observasi dalam program R. Apabila dataset siswa melampaui ambang batas tersebut, algoritma akan secara otomatis melakukan pengambilan sampel acak guna memperoleh sub-sampel yang representatif. Hal ini dilakukan agar uji normalitas tetap dapat dilaksanakan tanpa mengurangi validitas inferensi statistik secara signifikan. Pengujian ini sangat krusial dalam memvalidasi asumsi homogenitas varians sebelum dilakukan analisis komparatif lebih lanjut. Prosedur tersebut bertujuan untuk mengevaluasi apakah sebaran data pada kelompok SMA memiliki variansi yang setara dengan kelompok SMK. Interpretasi hasil didasarkan pada nilai p-value; apabila p-value > 0,05, maka varians antarkelompok dinyatakan homogen. Hal ini merupakan prasyarat fundamental bagi penggunaan uji statistik parametrik, seperti t-test atau ANOVA.

4. Pemilihan Uji Hipotesis Otomatis

Bagian ini akan melakukan sejalan perintah untuk memilih pendekatan apa yang baik untuk melakukan uji beda pada data tersebut.

```
134 ▾ if(normal_assumption && equal_var) {  
135   cat("=== UJI INDEPENDENT T-TEST (asumsi normal + varians homogen) ===\n")  
136   test_result <- t.test(jumlah_siswa_penerima_PIP ~ jenis_sek,  
137                         data = data_final,  
138                         var.equal = TRUE)  
139   print(test_result)  
140 ▾ } else if(normal_assumption && !equal_var) {  
141   cat("=== UJI WELCH T-TEST (asumsi normal + varians heterogen) ===\n")  
142   test_result <- t.test(jumlah_siswa_penerima_PIP ~ jenis_sek,  
143                         data = data_final,  
144                         var.equal = FALSE)  
145   print(test_result)  
146 ▾ } else {  
147   cat("=== UJI MANN-WHITNEY U (asumsi normalitas dilanggar) ===\n")  
148   test_result <- wilcox.test(jumlah_siswa_penerima_PIP ~ jenis_sek,  
149                             data = data_final)  
150   print(test_result)  
151 ▾ }
```

Prosedur penentuan uji statistik diawali dengan evaluasi distribusi data melalui uji normalitas Shapiro-Wilk. Apabila data terdistribusi secara normal ($p\text{-value} > 0,05$), analisis dilanjutkan menggunakan uji parametrik, seperti t-test. Sebaliknya, jika asumsi normalitas tidak terpenuhi ($p\text{-value} < 0,05$), sistem secara otomatis mengalihkan prosedur ke uji non-parametrik, seperti Wilcoxon atau Mann-Whitney, guna menjamin validitas hasil analisis. Selain evaluasi normalitas, dilakukan pula verifikasi sistematis terhadap homogenitas varians. Dalam kondisi di mana varians antarkelompok bersifat heterogen, diterapkan Welch T-Test. Metode ini dinilai lebih tangguh (robust) karena tidak mensyaratkan asumsi kesamaan varians, sehingga mampu mengakomodasi perbedaan sebaran data secara lebih presisi sekaligus meminimalkan risiko kesalahan tipe I.

5. Visualisasi Hasil

Bagian akhir ini berfungsi untuk merapikan hasil analisis agar sesuai dengan table APA. Hasil dari syntax ini akan menyajikan hasil data-datanya sesuai dengan table APA

```

182 tabel_apa <- data_final >
183 select(jenis_sek, jumlah_siswa_penerima_PIP) >
184 tbl_summary(
185   by = jenis_sek,
186   missing = "no",
187   statistic = list(all_continuous() ~ "{mean} ({sd})",
188   label = list(jumlah_siswa_penerima_PIP ~ "Jumlah Siswa Penerima PIP")
189 ) >
190 add_overall() >
191 add_difference(test = list(all_continuous() ~ jenis_uji_tabel)) >
192
193 modify_header(
194   label = "**Variabel**",
195   stat_1 = "**SMA**\nN = {n}",
196   stat_2 = "**SMK**\nN = {n}",
197   estimate = "**Mean Difference**",
198   conf.low = "**95% CI**", # gtsummary 2.0 menggabungkan low & high di kolom ini
199   p.value = "**p-value**"
200 ) >
201
202 modify_footnote(
203   everything() ~ NA,
204   p.value ~ "Diuji menggunakan penyesuaian asumsi (T-Test/Welch/Mann-Whitney)"
205 ) >
206
207 modify_caption("**Tabel 1**\n*Perbandingan Jumlah Siswa Penerima PIP antara SMA dan SMK*")
208 as_flex_table() >
209 theme_apa()

```

Karena saya membutuhkan hasil dari keseluruhan proses eksplorasi sehingga saya membutuhkan table yang telah terstandar.

6. Analisis Hasil Temuan

Tabel 1 *Perbandingan Jumlah Siswa Penerima PIP antara SMA dan SMK*						
Variabel	Overall N = 22,978	SMA N = 13026	SMK N = 9952	Mean Difference	95% CI	p-value ¹
Jumlah Siswa Penerima PIP	157 (162)	94 (70)	240 (205)	-86	-90, -83	<0.001

¹Diuji menggunakan penyesuaian asumsi (T-Test/Welch/Mann-Whitney)

Tabel 1. Uji Beda

Tabel 1 menyajikan perbandingan jumlah siswa penerima Program Indonesia Pintar (PIP) antara jenjang SMA dan SMK, dengan total 22.978 unit observasi yang terdiri atas 13.026 SMA dan 9.952 SMK. Secara keseluruhan, jumlah penerima PIP memiliki nilai tengah sebesar 157 siswa dengan variasi sebesar 162. Berdasarkan jenis sekolah, SMA memiliki jumlah penerima PIP sebesar 94 siswa (SD/IQR = 70), sedangkan SMK sebesar 240 siswa (SD/IQR = 205). Temuan ini menunjukkan bahwa SMK memiliki jumlah penerima PIP yang jauh lebih tinggi dibandingkan SMA, sekaligus menunjukkan variasi jumlah penerima yang lebih besar antarsmk dibandingkan antarsma. Hasil uji beda menunjukkan terdapat perbedaan yang signifikan secara statistik antara SMA dan SMK dalam jumlah siswa penerima PIP ($p < 0,001$). Selisih rerata/perbedaan lokasi yang

diperoleh sebesar -86 dengan interval kepercayaan 95% antara -90 hingga -83 . Nilai negatif tersebut mengindikasikan bahwa jumlah penerima PIP di SMA secara konsisten lebih rendah dibandingkan dengan SMK. Secara substantif, hasil ini mengindikasikan bahwa siswa di SMK cenderung lebih banyak menerima bantuan PIP dibandingkan dengan siswa di SMA. Hal tersebut dapat mencerminkan bahwa peserta didik di jalur kejuruan lebih banyak berasal dari kelompok ekonomi rentan atau adanya distribusi program yang lebih besar pada jenjang SMK. Namun demikian, tingginya variasi pada kelompok SMK menunjukkan adanya heterogenitas antarsekolah, sehingga faktor-faktor lain yang memengaruhi distribusi penerima PIP masih perlu diteliti lebih lanjut.